ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES

HONORIS UNITED UNIVERSITIES

RAPPORT DE Projet Deep Learning

Analyse des émotions Faciales

Filière : Ingénierie spécialisée en Intelligence Artificielle et Data

Réalisé par : KHAWLA BEKKAS

Année Universitaire : 2025/2026

RESUME

La reconnaissance des émotions faciales est un domaine important de l'intelligence artificielle et de la vision par ordinateur. Elle permet d'analyser automatiquement les expressions faciales afin d'identifier les émotions humaines. Dans ce projet, un système de reconnaissance des émotions basé sur le Deep Learning a été développé à l'aide du modèle MobileNetV2.

Le système utilise le dataset AffectNet pour l'entraînement et intègre plusieurs étapes, notamment la détection des visages, le prétraitement des images et la classification des émotions. Deux méthodes de détection ont été utilisées : Haar Cascade et YOLO, afin de comparer leurs performances. Une application web interactive développée avec Streamlit permet de tester le système sur des images simples, des images de groupe et des flux webcam en temps réel.

Les résultats obtenus montrent que le modèle atteint des performances satisfaisantes malgré certaines difficultés liées aux émotions visuellement proches et aux conditions complexes. Enfin, ce projet met également en évidence les enjeux éthiques liés à l'utilisation de la reconnaissance des émotions faciales, notamment en matière de vie privée, de biais des données et d'utilisation responsable de l'intelligence artificielle.

LISTE DES FIGURES

Figure 1:schéma des émotions de base 3
Figure 2:Local Binary Patterns (LBP) 4
Figure 3:Histogram of Oriented Gradients (HOG) 4
Figure 4:Gabor Wavelets 4
Figure 5:Active Appearance Models (AAM) 5
Figure 6:Modele SVM 5
Figure 7:Modele RandomForest 6
Figure 8:model Hidden Markov Models (HMM) 6
Figure 9:Model CNN 7
Figure 10:Chargement et redimensionnement des images avec flow_from_directory 13
Figure 11:Configuration de ImageDataGenerator pour l'augmentation des données 14
Figure 12:Génération des ensembles de validation et de test avec flow_from_directory 15
Figure 13:Chargement du modèle YOLOv8 pour la détection des visages 15
Figure 14:Logo python 16
Figure 15:Logo OpenCV 16
Figure 16:Logo TensorFlow / Keras 16
Figure 17:Logo YOLO 17
Figure 18:Logo streamlit 17
Figure 19:Logo matplotlib 18
Figure 20:Phase d'extraction de caractéristiques 21
Figure 21:Fine-tuning du modèle 22
Figure 22:Fonction de perte et optimiseur 23
Figure 23:Architecture globale du système de reconnaissance des émotions 25
Figure 24:Interface principale de l'application Streamlit 26
Figure 25:Exemple de prédiction sur une image simple 26
Figure 26:Exemple de prédiction sur une image de groupe 27
Figure 27:Utilisation de la webcam pour la détection des émotions 27
Figure 28:Évolution de l'accuracy et de la fonction de perte pendant l'entraînement 29
Figure 29:Matrice de confusion du modèle MobileNetV2 sur AffectNet 30
Figure 30:Comparaison des performances entre Haar Cascade et YOLO 31
Figure 31:Distribution des erreurs de classification par émotion 33
Figure 32:Aspects éthiques de la reconnaissance des émotions faciale 36

LISTE DES TABLEAUX

Table 1:Tableau comparatif des architectures MobileNet 8
Table 2:Comparaison des méthodes de reconnaissance des émotions 9
Table 3:Proprieter effectnet 12
Table 4: Tableaux de classe d'emotion 12
Table 5:Architecture du modèle MobileNetV2 pour la reconnaissance des émotions 20
Table 6:Tableau de Paramètres d'entraînement 22
Table 7:Performances globales du modèle 29

TABLE DE MATIÈRES

RESUME 2
LISTE DES FIGURES 3
LISTE DES TABLEAUX 4
TABLE DE MATIÈRES 5
INTRODUCTION GENERALE 1
Contexte du projet : 1
Problématique : 1
Objectifs du projet: 1
Chapitre 1 : Revue de littérature 2
1.1 Introduction à la reconnaissance des émotions 3
1.2 Importance des émotions dans les systèmes intelligents 3
1.3 Méthodes traditionnelles de reconnaissance faciale 3
1.3.1 Extraction de caractéristiques classiques 4
1.3.2 Classifieurs traditionnels 5
1.4 Approches basées sur le Deep Learning 6
1.4.1 CNN de base 6
1.4.2 Transfer Learning 7
1.4.3 Architectures légères pour l'embarqué 7
1.4.4YOLO pour la détection des visages 9
1.4.5 Vision Transformers (ViT) 9
1.5 Travaux existants et études comparatives 9
1.6 Limites des approches existantes 10
Chapitre 2 : Données et Prétraitement 11
2.1 Présentation du dataset 12
2.1.1 AffectNet : Dataset utilize 12
2.2 Description des classes d'émotions 12
2.3 Prétraitement des images 13
2.4 Répartition des données 14
2.6 Détection des visages avec YOLO 15
2-7 Environnement et outils : 16
Chapitre 3 : Méthodologie et Modèle 19
3.1 Choix du modèle :MobileNetV2 20

3.2 Architecture du modèle 20
3.3 Extraction de caractéristiques (Phase 1) 21
3.4 Fine-tuning du modèle (Phase 2) 21
3.5 Paramètres d'entraînement 22
3.6 Fonction de perte et optimiseur 23
Chapitre 4: Implémentation du système 24
4.1 Architecture globale du system 25
4.2 Méthodes de détection 25
4.3 Pipeline de reconnaissance des émotions 25
4.4 Application Streamlit 26
4.5 Modes de fonctionnement 26
4.5.1 Image simple 26
4.5.2 Image de groupe 27
4.5.3 Webcam 27
Chapitre 5 : Résultats et Évaluation 28
5.1 Métriques d'évaluation 29
5.2 Résultats expérimentaux 29
5.3 Matrice de confusion 30
5.4 Analyse des performances 31
5.5 Comparaison des méthodes de détection (Haar Cascade vs YOLO) 31
Chapitre 6 : Discussion et Limites 32
6.1 Analyse des erreurs 33
6.2 Cas problématiques 33
6.3 Impact de la qualité des données 34
6.4 Limites du modèle 34
6.5 Améliorations possibles 34
Chapitre 7 : Aspects éthiques 35
7.1 Analyse éthique du système 36
7.2 Fiche éthique 36
7.3 Recommandations d'usage 37
CONCLUSION GENERALE 38
WEBOGRAPHIE 39

INTRODUCTION GENERALE

Contexte du projet :

Avec l'évolution rapide de l'intelligence artificielle, les systèmes capables de comprendre et d'interpréter les émotions humaines occupent une place de plus en plus importante. La reconnaissance des émotions faciales constitue un domaine clé, notamment dans des applications telles que les interfaces homme-machine, les systèmes de surveillance intelligente, l'e-learning ou encore le marketing. Grâce aux avancées du Deep Learning, et en particulier des réseaux de neurones convolutifs (CNN), il est désormais possible d'analyser automatiquement des images et d'en extraire des informations complexes, comme les expressions faciales. Des modèles légers et performants comme MobileNetV2 permettent même une utilisation en temps réel, ce qui ouvre la voie à des applications interactives. Dans ce contexte, ce projet s'inscrit dans le développement d'un système intelligent capable de détecter les visages et de reconnaître les émotions à partir d'images.

Problématique :

Malgré les progrès réalisés, la reconnaissance automatique des émotions reste un défi en raison de la variabilité des expressions faciales (éclairage, angle, occlusions, diversité des individus). De plus, la détection des visages dans les images de groupe peut générer des erreurs (faux visages, mauvais recadrage), ce qui affecte la performance globale du système. Ainsi, la problématique principale est : Comment concevoir un système fiable capable de détecter les visages et reconnaître correctement les émotions, aussi bien en image simple qu'en image de groupe, tout en restant performant en temps réel ?

Objectifs du projet:

- Développer un système complet de reconnaissance des émotions faciales.
- Entraîner un modèle MobileNetV2 avec le transfer learning sur AffectNet.
- Utiliser une stratégie d'entraînement basée sur l'extraction de caractéristiques et le fine-tuning.
- Gérer le déséquilibre des données par augmentation et pondération des classes.
- Déployer une application temps réel avec OpenCV et Streamlit.
- Évaluer les performances du système à l'aide de plusieurs métriques et analyser les erreurs obtenues.

Chapitre 1 : Revue de littérature

1.1 Introduction à la reconnaissance des émotions

La reconnaissance des émotions faciales consiste à identifier automatiquement les expressions du visage humain afin de déterminer l'état émotionnel d'un individu. Les émotions de base généralement étudiées incluent la joie, la tristesse, la colère, la surprise, la peur et le dégoût. Ce domaine combine des connaissances issues de la psychologie, de la vision par ordinateur et de l'intelligence artificielle. Avec l'évolution des technologies, les systèmes automatisés sont capables d'analyser des images ou des vidéos pour détecter et interpréter ces expressions, ce qui ouvre la voie à de nombreuses applications innovantes.

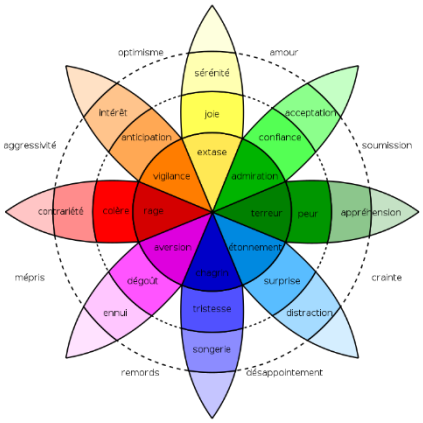


Figure 1:schéma des émotions de base

1.2 Importance des émotions dans les systèmes intelligents

L'intégration de la reconnaissance des émotions dans les systèmes intelligents ouvre des perspectives considérables dans de nombreux domaines applicatifs :

- Interfaces homme-machine adaptatives : ajustement de l'interface en fonction de l'état émotionnel de l'utilisateur.
- Santé mentale : détection précoce de la dépression, du stress, ou de troubles anxieux.
- Éducation : adaptation du rythme d'apprentissage en fonction de l'engagement de l'étudiant.
- Sécurité et surveillance : détection d'états de détresse ou d'hostilité dans des espaces publics.
- Automobile : systèmes anti-somnolence pour la conduite assistée.
- Marketing et UX : analyse des réactions émotionnelles face à des produits ou contenus.

1.3 Méthodes traditionnelles de reconnaissance faciale

Avant l'avènement du deep learning, la reconnaissance des émotions reposait sur un pipeline en deux étapes : extraction manuelle de caractéristiques puis classification.

1.3.1 Extraction de caractéristiques classiques

Les méthodes traditionnelles reposent sur l'extraction manuelle de caractéristiques à partir des images faciales. Parmi les techniques les plus utilisées :

- **Local Binary Patterns (LBP)** : technique d'encodage de la texture locale autour de chaque pixel, robuste face aux variations d'illumination.

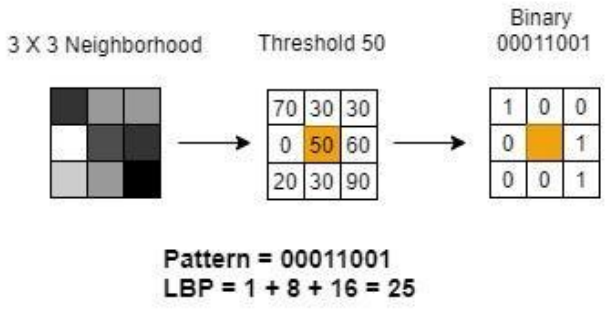


Figure 2:Local Binary Patterns (LBP)

- **Histogram of Oriented Gradients (HOG)** : méthode qui capture les gradients directionnels afin de représenter la forme des régions faciales.

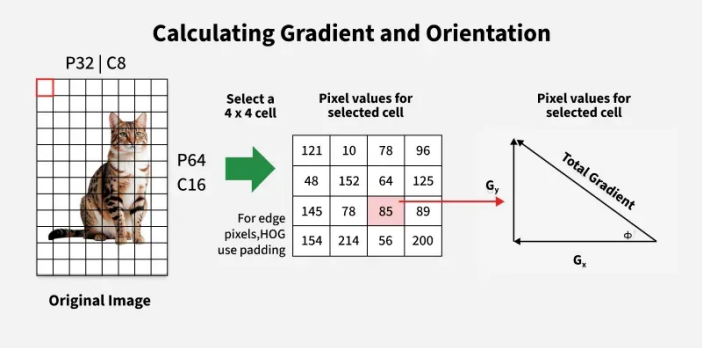


Figure 3:Histogram of Oriented Gradients (HOG)

- **Gabor Wavelets** : filtres sensibles à l'orientation et à la fréquence, particulièrement adaptés à l'analyse de la texture de la peau.

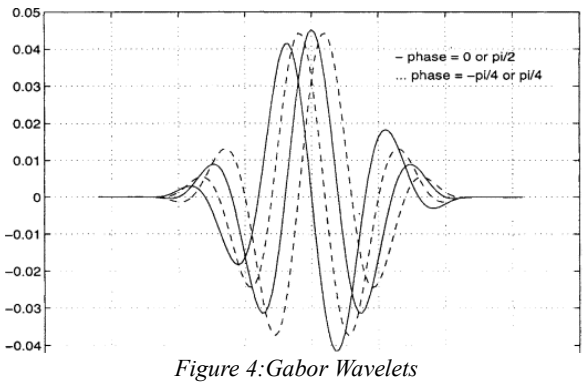


Figure 4:Gabor Wavelets

- **Active Appearance Models (AAM)** : modèles statistiques combinant la forme et la texture du visage pour représenter les variations faciales.

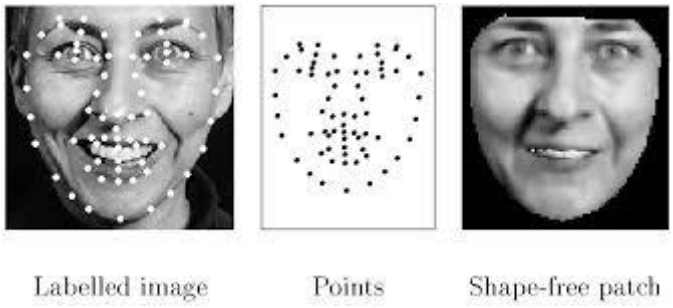


Figure 5:Active Appearance Models (AAM)

1.3.2 Classifieurs traditionnels

Une fois les caractéristiques extraites, différents classifieurs sont utilisés pour reconnaître les émotions :

- **Support Vector Machine (SVM)** : st un algorithme de machine learning supervisé qui classifie les données en trouvant une ligne optimale ou un hyperplan qui maximise la distance entre chaque classe dans un espace à n dimensions.

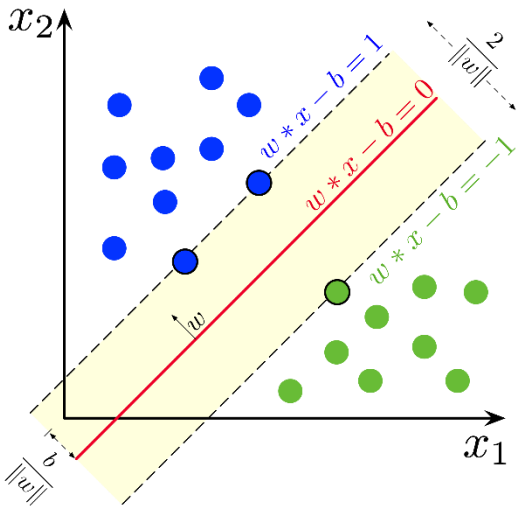


Figure 6:Modele SVM

- **Random Forest**: est un modèle d'apprentissage automatique qui utilise de nombreux arbres de décision, formant une « forêt », pour effectuer une prédiction. Ces arbres peuvent être visualisés comme un organigramme des conditions permettant de classifier ou de prédire les résultats avec la plus grande précision. Les décisions ou prédictions du modèle sont issues d'une approche agrégée, basée sur les résultats combinés de tous les arbres de la forêt.

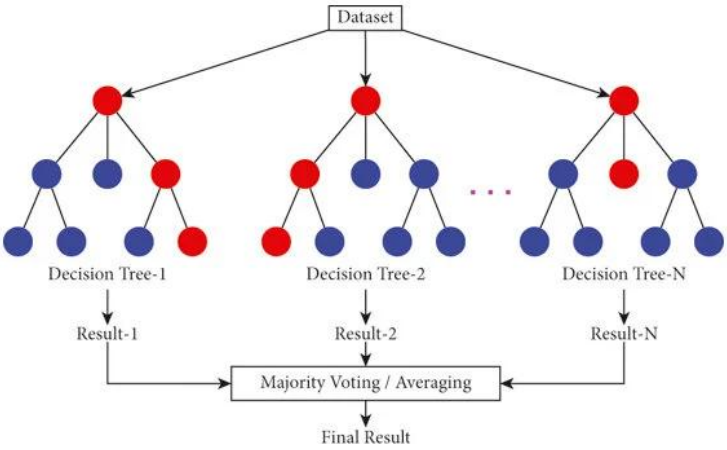


Figure 7:Modele RandomForest

- **Hidden Markov Models (HMM)** : Les modèles statistiques analysent des séquences d'observations en inférant une chaîne d'états sous-jacente et non observée (cachée). Ils sont largement utilisés en reconnaissance de formes, en reconnaissance vocale et en bioinformatique pour prédire des états cachés, tels que les étiquettes morphosyntaxiques des mots, à partir des probabilités de transition et d'émission.

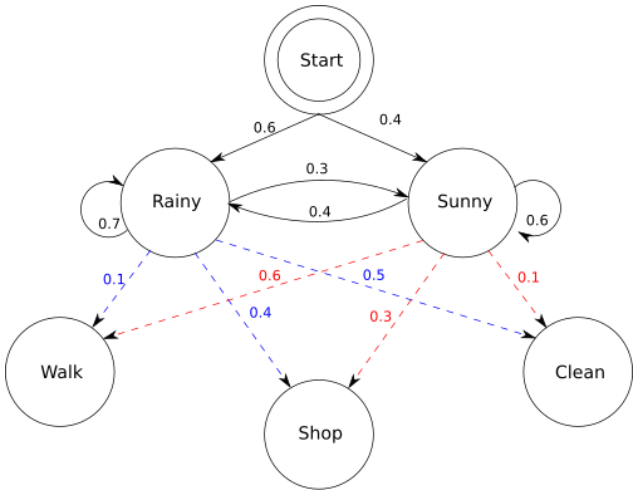


Figure 8:model Hidden Markov Models (HMM)

1.4 Approches basées sur le Deep Learning

1.4.1 CNN de base

Un réseau de neurones convolutif (CNN) est un type de réseau de neurones artificiel spécialement conçu pour analyser des données visuelles. Inspiré de notre propre système visuel, un réseau CNN apprend à "voir" le monde en identifiant des tendances dans les données visuelles. Mais sa principale force ne réside pas seulement dans la reconnaissance

d'images. Elle est aussi capable d'identifier des schémas dans n'importe quel type de données présentant une structure en grille, qu'il s'agisse de spectrogrammes audios ou de scans médicaux en 3D.

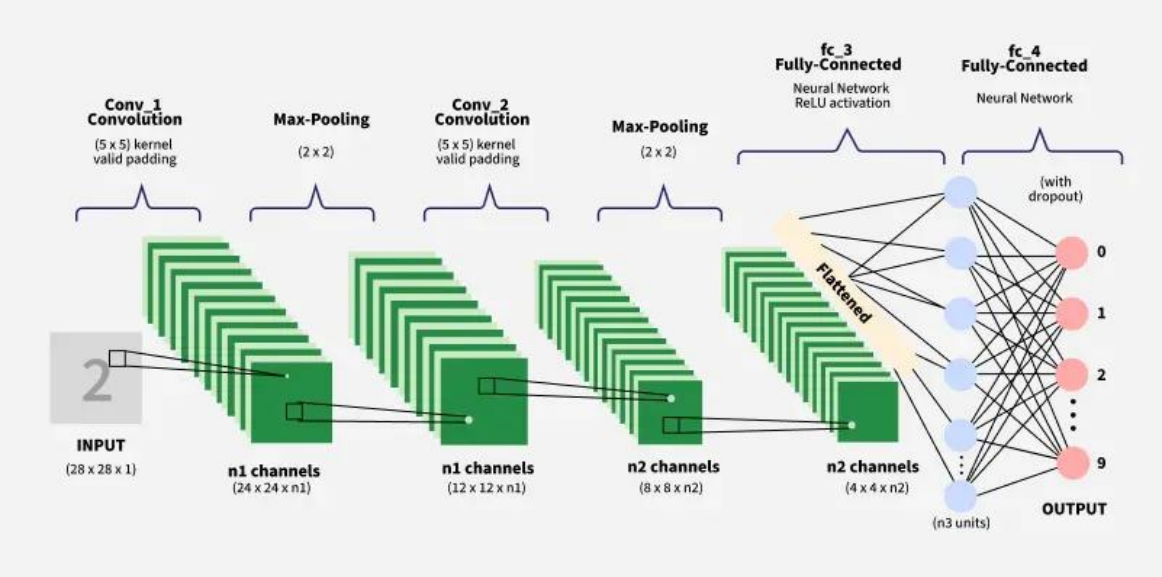


Figure 9:Model CNN

1.4.2 Transfer Learning

L'apprentissage par transfert est une technique d'apprentissage automatique qui consiste à utiliser les connaissances acquises lors d'une tâche ou avec un ensemble de données pour améliorer les performances d'un modèle sur une autre tâche connexe ou avec un ensemble de données différent.

1.4.3 Architectures légères pour l'embarqué

Les architectures de réseaux de neurones convolutionnels ont évolué au fil du temps afin d'améliorer les performances en vision par ordinateur. Plusieurs modèles importants ont marqué cette évolution.

MobileNet:

MobileNet est une famille d'architectures de réseaux de neurones convolutifs (CNN - Convolutional Neural Networks) conçue par Google pour être légère, efficace et performante sur les appareils mobiles et embarqués. Contrairement aux CNN lourds comme VGG, MobileNet utilise des convolutions séparables en profondeur (depthwise separable convolutions) pour réduire considérablement le nombre de paramètres et de calculs, permettant une reconnaissance d'images en temps réel sur smartphone.

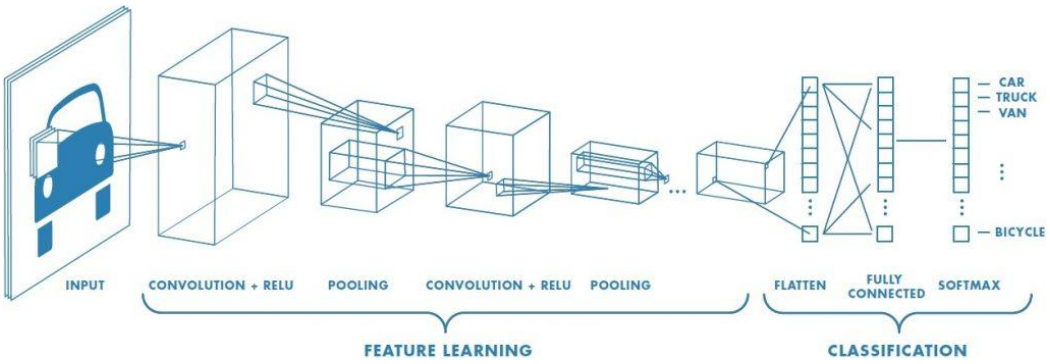


Figure 10:Architecture MobileNet

Voici la différence entre les versions principales :

- **MobileNet V1 (2017) :** Introduit les convolutions séparables en profondeur (depthwise separable convolutions), ce qui réduit considérablement le nombre de paramètres et de calculs par rapport aux CNN classiques, tout en restant très léger.

Caractéristique	**MobileNet V1**	**MobileNet V2**	**MobileNet V3**
Nouveauté principale	Convolutions séparables en profondeur	Résidus inversés et bottlenecks linéaires	NAS (Neural Architecture Search) et Hard-Swish
Vitesse d'exécution	Rapide	Plus rapide	Très rapide
Précision	Bonne	Meilleure que V1	Excellente
Taille du modèle	Légère	Très légère	Compacte et optimisée

Table 1:Tableau comparatif des architectures MobileNet

- **MobileNet V2 (2018) :** Améliore la V1 en introduisant des **résidus inversés** (inverted residuals) et des goulots d'étranglement linéaires (linear bottlenecks). Cela permet d'obtenir une meilleure précision avec moins de paramètres, en conservant l'information importante entre les couches.
- **MobileNet V3 (2019) :** Optimisé par la recherche d'architecture neuronale (NAS) et l'algorithme NetAdapt. Il est plus rapide et plus compact que la V2. Il utilise de nouvelles fonctions d'activation (**Hard-Swish**) et intègre le mécanisme d'attention "Squeeze-and-Excitation" pour une meilleure précision.

SqueezeNet: est une architecture CNN légère et performante, développée en 2016 par des chercheurs de DeepScale, de l'UC Berkeley et de Stanford. Elle atteint une précision équivalente à celle d'AlexNet sur ImageNet avec 50 fois moins de paramètres, ce qui la rend idéale pour le calcul en périphérie et les applications mobiles. Sa principale caractéristique est le « module Fire », qui utilise des filtres pour réduire le nombre de paramètres, offrant ainsi des modèles compacts, rapides et hautement compressés.

EfficientNet: est une famille de réseaux de neurones convolutifs (CNN) conçue pour la classification d'images, offrant une précision de pointe tout en optimisant l'efficacité. Contrairement aux approches traditionnelles, il utilise une "mise à l'échelle composée" (compound scaling) qui équilibre uniformément la profondeur, la largeur et la résolution du modèle. Cette méthode permet d'obtenir des modèles plus petits et beaucoup plus rapides que les CNN classiques.

1.4.4YOLO pour la détection des visages

YOLO (You Only Look Once) est une famille de modèles de détection d'objets basés sur des réseaux neuronaux convolutifs. Contrairement aux approches classiques, YOLO effectue la détection en une seule étape (single-stage), en analysant l'image en un seul passage, ce qui le rend très rapide et adapté aux applications en temps réel. Depuis son introduction en 2015, YOLO a connu plusieurs améliorations (YOLOv8 à YOLOv26), offrant une meilleure précision et une efficacité accrue, notamment pour les systèmes embarqués. Ce modèle est largement utilisé pour des tâches telles que la détection d'objets, le suivi, la segmentation et la classification d'images.

1.4.5 Vision Transformers (ViT)

Est un transformateur adapté aux tâches de vision par ordinateur. Une image est divisée en patchs de taille fixe, traités comme une séquence de jetons, à l'instar des mots en traitement automatique du langage naturel (TALN). ViT nécessite moins de ressources pour le pré-entraînement que les architectures convolutionnelles, et ses performances sur de grands ensembles de données sont transposables à des tâches avales plus petites.

1.5 Travaux existants et études comparatives

Modèle	Dataset	Accuracy	Remarques
VGG-16 Fine-tuned	FER2013	**71.2%**	*Lourd, lent sur CPU*
ResNet-50	AffectNet-7	**63.5%**	*Bonne généralisation*
MobileNetV2	AffectNet-5	**~70%**	*Léger, temps réel*
EfficientNet-B2	AffectNet-7	**66.8%**	*Meilleur compromis*
Vision Transformer	RAF-DB	**88.1%**	*Etat de l'art, GPU requis*
Humains	FER2013	**~65%**	*Référence humaine*

Table 2:Comparaison des méthodes de reconnaissance des émotions

1.6 Limites des approches existantes

Malgré les avancées en reconnaissance des émotions faciales, plusieurs limites persistent. Les modèles restent sensibles aux conditions d'acquisition comme l'éclairage, l'angle ou les occlusions, ce qui peut réduire leur précision. La variabilité des expressions selon les individus et les cultures rend également la généralisation difficile. De plus, les images de groupe compliquent la détection des visages, entraînant des erreurs de classification. Certaines émotions proches visuellement (neutral, sad, anger) sont souvent confondues. Les performances dépendent aussi fortement de la qualité et de l'équilibre des données d'entraînement, pouvant introduire des biais. Enfin, les modèles les plus performants nécessitent des ressources importantes, ce qui limite leur utilisation en temps réel.

Chapitre 2 : Données et Prétraitement

2.1 Présentation du dataset

2.1.1 AffectNet : Dataset utilize

AffectNet est la plus grande base de données publique d'expressions faciales en conditions réelles (« in-the-wild »), contenant plus **de 1 million d'images**. Elle est conçue pour la reconnaissance automatique des émotions faciales (FER). Ce dataset est largement utilisé en affective computing pour entraîner des modèles de vision par ordinateur capables de reconnaître les émotions à partir de visages capturés dans des environnements non contrôlés, caractérisés par des variations d'éclairage, d'arrière-plan et de sujets.

Propriété	Valeur
Taille totale	400 000+ images annotées
Source	Moteurs de recherche (Google, Bing, DuckDuckGo)
Mots-clés	Environ 1250 mots-clés émotionnels en 6 langues
Annotation	Manuelle par annotateurs humains formés
Classes disponibles	8 (colère, mépris, dégoût, peur, joie, neutre, tristesse, surprise)
Classes retenues	5 : Anger, Happy, Neutral, Sad, Surprise
Format	Images couleur RGB, résolution variable
Défi principal	Fort déséquilibre : Happy (130K+) vs Disgust (~3 800)

Table 3:Proprieter effectnet

2.2 Description des classes d'émotions

Classe	Emoji	Description	Défis
Anger	😠	Sourcils froncés, regard intense	Confusion avec Sad
Happy	😊	Sourire, yeux plissés	Classe dominante
Neutral	😐	Expression neutre	Ambiguë
Sad	😢	Expression triste, regard bas	Confusion avec Anger
Surprise	😲	Yeux ouverts, bouche ouverte	Expression rapide

Table 4: Tableaux de classe d'emotion

2.3 Prétraitement des images

Avant l'entraînement du modèle, les images du dataset AffectNet sont soumises à un processus de prétraitement automatisé afin de garantir leur compatibilité avec l'architecture utilisée et d'améliorer la performance globale. Dans ce projet, le prétraitement est réalisé à l'aide de la classe ImageDataGenerator de Keras, ce qui permet d'appliquer les transformations en temps réel lors du chargement des données.

Redimensionnement des images

Les images sont automatiquement redimensionnées à une taille uniforme de 96×96 pixels via la fonction flow_from_directory. Cette dimension correspond à la taille d'entrée recommandée pour le modèle MobileNetV2.

```
train_generator = train_datagen.flow_from_directory(
    TRAIN_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode="categorical",
    subset="training",
    shuffle=True
)

val_generator = train_datagen.flow_from_directory(
    TRAIN_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode="categorical",
    subset="validation",
```

Figure 10:Chargement et redimensionnement des images avec flow_from_directory

Augmentation des données

Afin d'améliorer la capacité de généralisation du modèle et de simuler des conditions réelles, une augmentation de données est appliquée en temps réel. Elle consiste à effectuer plusieurs transformations telles que la rotation, le zoom, les décalages horizontaux et verticaux, ainsi que le retournement horizontal. Ces techniques permettent d'enrichir le jeu de données sans duplication explicite.

```
train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input,
    validation_split=0.2,
    horizontal_flip=True,
    rotation_range=15,
    zoom_range=0.15,
    width_shift_range=0.1,
    height_shift_range=0.1,
    brightness_range=[0.8, 1.2],
    # ✅ FIX 2: Added shear and channel shift for more robust augmentation
    shear_range=0.1,
    channel_shift_range=20.0
)
```

Figure 11:Configuration de ImageDataGenerator pour l'augmentation des données

2.4 Répartition des données

Afin d'assurer un entraînement efficace et une évaluation fiable du modèle, les données sont divisées en trois sous-ensembles : entraînement, validation et test. Dans ce projet, la répartition est réalisée à l'aide de la fonction flow_from_directory de Keras.

- **Ensemble d'entraînement (Train)** : utilisé pour apprendre les paramètres du modèle à partir des images contenues dans le dossier principal.
- **Ensemble de validation (Validation)** : extrait automatiquement du dossier d'entraînement grâce au paramètre subset="validation" dans flow_from_directory. Il permet d'évaluer les performances du modèle pendant l'entraînement et de détecter le surapprentissage.
- **Ensemble de test (Test)** : chargé séparément à partir du dossier TEST_DIR, il est totalement indépendant et utilisé uniquement pour l'évaluation finale du modèle.

```python
train_generator = train_datagen.flow_from_directory(
    TRAIN_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode="categorical",
    subset="training",
    shuffle=True
)

val_generator = train_datagen.flow_from_directory(
    TRAIN_DIR,
    target_size=(IMG_SIZE, IMG_SIZE),
    batch_size=BATCH_SIZE,
    class_mode="categorical",
    subset="validation",
    shuffle=False
```

Figure 12:Génération des ensembles de validation et de test avec flow_from_directory

2.6 Détection des visages avec YOLO

Dans le cadre de l'application finale, une étape de détection des visages a été intégrée afin d'améliorer la qualité des entrées du modèle de reconnaissance des émotions. Pour cela, le modèle YOLOv8 a été utilisé, avec une version spécialisée pour la détection des visages (yolov8n-face.pt). Ce modèle permet une détection rapide et précise en temps réel. Afin d'optimiser les performances de l'application, le modèle YOLO est chargé une seule fois grâce au mécanisme de cache fourni par Streamlit, évitant ainsi un rechargement inutile à chaque exécution.

```python
@st.cache_resource
def load_yolo():
    return YOLO("models/yolov8n-face.pt")
```

Figure 13:Chargement du modèle YOLOv8 pour la détection des visages

Cette fonction permet de charger le modèle YOLO de manière efficace et de le réutiliser tout au long de l'exécution de l'application.

Le modèle est ensuite utilisé pour :

- Détecter les visages dans les images ou flux vidéo,
- Extraire les régions d'intérêt (ROI),
- Transmettre ces régions au modèle CNN pour la classification des émotions.

2-7 Environnement et outils :

Python :



Figure 14:Logo python

Fonctionnalité dans le projet : python est le langage principal utilisé pour implémenter l'ensemble du système. Il permet de gérer le flux de traitement, depuis le chargement des images jusqu'à la prédiction des émotions.

But : Assurer une implémentation flexible, reproductible et facilement extensible.

OpenCV:



Figure 15:Logo OpenCV

Fonctionnalité dans le projet : OpenCV est utilisé pour le traitement des images, notamment la lecture, le redimensionnement et la manipulation des images. Il est également utilisé pour implémenter la détection des visages avec Haar Cascade.

But : Faciliter la préparation des images et la détection des visages.

TensorFlow / Keras:



Figure 16:Logo TensorFlow / Keras

Fonctionnalité dans le projet : TensorFlow et Keras sont utilisés pour la construction et l'entraînement du modèle MobileNetV2. Ils permettent de définir l'architecture du réseau de neurones et d'effectuer l'apprentissage.

But : Implémenter et entraîner le modèle de reconnaissance des émotions.

YOLO (Ultralytics):



Figure 17:Logo YOLO

Fonctionnalité dans le projet : YOLO est utilisé pour la détection avancée des visages. Il permet une détection rapide et précise, notamment dans des conditions complexes comme les images de groupe.

But : Améliorer la robustesse de la détection des visages.

Streamlit:



Figure 18:Logo streamlit

Fonctionnalité dans le projet : Streamlit est utilisé pour développer l'interface web interactive de l'application. Il permet de créer rapidement une interface permettant à l'utilisateur de tester le système.

But : Offrir une interface simple et intuitive pour l'utilisation du système.

Matplotlib / outils de visualisation :



Figure 19:Logo matplotlib

Fonctionnalité dans le projet : Matplotlib est utilisé pour la visualisation des résultats expérimentaux. Il permet de générer des graphiques tels que les courbes d'apprentissage (accuracy et loss), la matrice de confusion, ainsi que des graphiques de comparaison entre les méthodes de détection (Haar Cascade et YOLO).

But : Faciliter l'analyse des performances du modèle et rendre les résultats clairs, interprétables et comparables dans le rapport.

Chapitre 3 : Méthodologie et Modèle

3.1 Choix du modèle :MobileNetV2

Dans le cadre de ce projet, le modèle MobileNetV2 a été retenu pour la reconnaissance des émotions faciales. Ce choix est motivé par plusieurs raisons. Tout d'abord, MobileNetV2 est une architecture légère et efficace, adaptée aux applications en temps réel. Contrairement aux modèles plus complexes, il nécessite moins de ressources tout en offrant de bonnes performances. Ensuite, l'utilisation des résidus inversés (inverted residuals) et des goulots d'étranglement linéaires (linear bottlenecks) permet d'améliorer la précision tout en réduisant le nombre de paramètres. De plus, le modèle est pré-entraîné sur ImageNet, ce qui permet d'exploiter le transfer learning pour accélérer l'apprentissage et améliorer la généralisation sur le dataset AffectNet. Enfin, ce modèle est particulièrement adapté à l'intégration dans une application en temps réel développée avec Streamlit, où la rapidité d'inférence est essentielle. Ainsi, MobileNetV2 représente un compromis optimal entre performance, rapidité et efficacité, ce qui en fait un choix pertinent pour ce projet.

3.2 Architecture du modèle

L'architecture complète du système est construite à partir de **MobileNetV2**, auquel une tête de classification personnalisée est ajoutée pour prédire les 5 émotions retenues.

	Couche	**Sortie**	**Params**	**Rôle**
1	Input Layer	(96, 96, 3)	0	Image RGB normalisée
2	MobileNetV2 Base	(3, 3, 1280)	2,257,984	Extraction des caractéristiques
3	GlobalAveragePooling2D	(1280)	0	Réduction spatiale globale
4	BatchNormalization	(1280)	5,120	Stabilisation de l'entraînement
5	Dense 256 (ReLU)	(256)	327,936	Classification intermédiaire
6	Dropout 0.4	(256)	0	Régularisation
7	Dense 128 (ReLU)	(128)	32,896	Représentation compacte
8	Dropout 0.3	(128)	0	Régularisation
9	Dense 5 (Softmax)	(5)	645	Classification des 5 émotions

Table 5:Architecture du modèle MobileNetV2 pour la reconnaissance des émotions

3.3 Extraction de caractéristiques (Phase 1)

Dans cette première phase, le modèle MobileNetV2 est utilisé comme extracteur de caractéristiques pré-entraîné. L'ensemble des couches de la base est gelé (base_model.trainable = False), ce qui signifie que leurs poids ne sont pas mis à jour durant l'entraînement. Cette approche permet de tirer parti des connaissances acquises sur le dataset ImageNet, tout en réduisant le risque de surapprentissage et le temps d'entraînement. Seules les couches de classification ajoutées au-dessus de MobileNetV2 sont entraînées. Cela permet au modèle d'apprendre à associer les caractéristiques extraites aux différentes classes d'émotions. De plus, le modèle est utilisé en mode inférence (training=False) lors du passage dans MobileNetV2, afin de conserver le comportement des couches de normalisation (Batch Normalization) pré-entraînées.

```
base_model = MobileNetV2(
    weights="imagenet",
    include_top=False,
    input_shape=(IMG_SIZE, IMG_SIZE, 3)
)

base_model.trainable = False

inputs = Input(shape=(IMG_SIZE, IMG_SIZE, 3))
x = base_model(inputs, training=False)
x = GlobalAveragePooling2D()(x)
# ✅ FIX 4: Added BatchNormalization + larger Dense
x = BatchNormalization()(x)
x = Dense(256, activation="relu")(x)
x = Dropout(0.4)(x)
x = Dense(128, activation="relu")(x)
```

Figure 20:Phase d'extraction de caractéristiques

3.4 Fine-tuning du modèle (Phase 2)

Après la phase d'extraction de caractéristiques, une étape de fine-tuning est appliquée afin d'améliorer les performances du modèle. Contrairement à la première phase, une partie des couches de MobileNetV2 est dégelée pour permettre un ajustement aux données du dataset AffectNet. Dans ce projet, seules les **30 dernières couches** sont rendues entraînables, tandis que les autres restent gelées. Le modèle est ensuite réentraîné avec un **taux d'apprentissage faible**, ce qui permet d'améliorer la précision tout en évitant le surapprentissage. Cette étape permet ainsi une meilleure adaptation du modèle aux expressions faciales.

```python
for i, layer in enumerate(best_model.layers):
    print(i, layer.name)

base_model = best_model.layers[1]
base_model.trainable = True

# ✅ FIX 8: Unfreeze top 30 layers instead of only 10
for layer in base_model.layers[:-30]:
    layer.trainable = False

for layer in base_model.layers[-30:]:
    layer.trainable = True

print("Total layers:", len(base_model.layers))
print("Trainable layers:", sum(layer.trainable for layer in base_model.layers))
```

Figure 21:Fine-tuning du modèle

3.5 Paramètres d'entraînement

Paramètre	Extraction	Fine-Tuning
Optimiseur	Adam	Adam
Learning Rate	1e-4	1e-5
Batch Size	16	16
IMG_SIZE	**96×96**	**96×96**
Epochs maximum	30	20
EarlyStopping patience	8	5
ReduceLROnPlateau patience	3	2
ReduceLROnPlateau factor	0.5	0.5
Learning rate minimum	1e-7	1e-7
Couches entraînables	Tête Dense uniquement	30 dernières couches MobileNetV2
Poids de classes	Oui (balanced)	Oui (balanced)

Table 6:Tableau de Paramètres d'entraînement

3.6 Fonction de perte et optimiseur

Dans ce projet, le modèle est entraîné à l'aide de la fonction de perte **categorical_crossentropy**, adaptée aux problèmes de classification multiclasse. Cette fonction permet de mesurer l'écart entre les prédictions du modèle et les vraies classes, en pénalisant les mauvaises classifications. L'optimisation du modèle est réalisée à l'aide de l'optimiseur **Adam (Adaptive Moment Estimation)**, choisi pour sa rapidité de convergence et sa capacité à ajuster automatiquement le taux d'apprentissage. Il permet ainsi d'obtenir un apprentissage stable et efficace.

```
model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-4),
    loss="categorical_crossentropy",
    metrics=["accuracy"]
)
```

Figure 22:Fonction de perte et optimiseur

Chapitre 4: Implémentation du système

4.1 Architecture globale du system

L'architecture globale du système repose sur un pipeline complet allant de l'acquisition de l'image jusqu'à l'affichage du résultat. L'image d'entrée (upload ou caméra) est d'abord traitée par un module de détection de visages utilisant soit Haar Cascade, soit YOLO. Les visages détectés sont ensuite extraits et prétraités avant d'être transmis au modèle MobileNetV2 pour la classification des émotions. Les résultats sont finalement affichés dans l'interface Streamlit sous forme d'annotations et de probabilités.



Figure 23:Architecture globale du système de reconnaissance des émotions

4.2 Méthodes de détection

Haar Cascade : La méthode Haar Cascade est une approche classique basée sur des caractéristiques visuelles prédéfinies. Elle permet une détection rapide des visages frontaux avec un faible coût de calcul. Dans ce projet, le classifieur *haarcascade_frontalface_default.xml* est utilisé avec des paramètres optimisés. Toutefois, cette méthode présente des limitations dans des conditions complexes, notamment en cas de variations d'éclairage, de visages de profil ou d'occlusions.

YOLOv8 (You Only Look Once): Le modèle YOLOv8-face est une approche basée sur le deeplearning, capable de détecter les visages en temps réel avec une grande précision. Il analyse l'image en une seule passe et offre une meilleure robustesse face aux conditions difficiles, comme les images de groupe ou les angles variés. Dans ce projet, le modèle yolov8n-face.pt est utilisé, offrant un bon compromis entre vitesse et précision. Cette méthode est privilégiée dans l'application finale pour améliorer la qualité de détection.

4.3 Pipeline de reconnaissance des émotions

Le pipeline du système comprend plusieurs étapes successives : la détection des visages, l'extraction des régions d'intérêt, le prétraitement des images (redimensionnement et normalisation), puis la classification à l'aide du modèle MobileNetV2. Cette approche permet d'assurer une bonne précision tout en maintenant des performances adaptées au temps réel.

4.4 Application Streamlit

Une application web interactive a été développée à l'aide de Streamlit afin de rendre le système accessible et facile à utiliser. Cette application permet à l'utilisateur de charger une image, d'utiliser la webcam ou encore d'analyser des images de groupe. Elle offre également la possibilité de choisir la méthode de détection, notamment entre Haar Cascade et YOLO. En plus de ces fonctionnalités, l'interface intègre l'affichage des probabilités pour chaque émotion détectée, ainsi qu'une option permettant de télécharger les résultats obtenus.

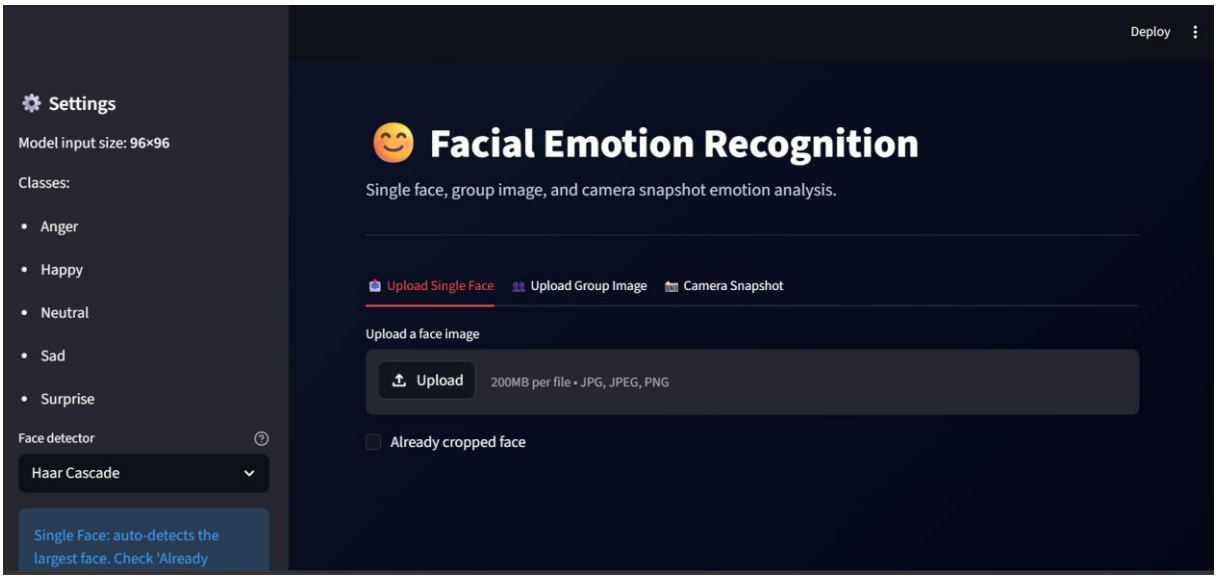


Figure 24:Interface principale de l'application Streamlit

4.5 Modes de fonctionnement

L'application propose plusieurs modes d'utilisation adaptés à différents cas d'usage.

4.5.1 Image simple

Ce mode permet d'analyser une image contenant un seul visage. Le système détecte automatiquement le visage principal en utilisant soit Haar Cascade, soit YOLO, selon le choix de l'utilisateur. Le modèle de classification est ensuite appliqué afin de prédire l'émotion, qui est affichée avec son niveau de confiance.

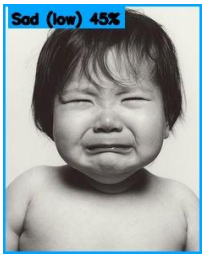


Figure 25:Exemple de prédiction sur une image simple

4.5.2 Image de groupe

Ce mode permet d'analyser des images contenant plusieurs visages. Chaque visage est détecté individuellement à l'aide de Haar Cascade ou YOLO, puis une prédiction est effectuée pour chaque personne. Une émotion globale peut également être déterminée à partir des résultats individuels.

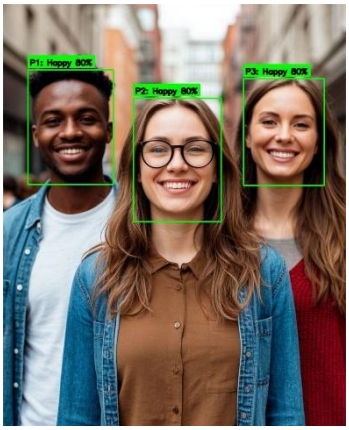


Figure 26:Exemple de prédiction sur une image de groupe

4.5.3 Webcam

Ce mode permet de capturer une image en temps réel à l'aide de la webcam. Le système applique ensuite le pipeline complet de détection et de classification des émotions.

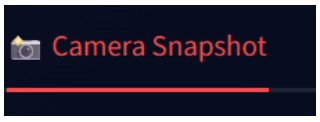


Figure 27:Utilisation de la webcam pour la détection des émotions

Chapitre 5 : Résultats et Évaluation

5.1 Métriques d'évaluation

Les performances du modèle sont évaluées à l'aide de plusieurs métriques adaptées à la classification multiclasse. L'accuracy mesure le pourcentage de prédictions correctes réalisées par le modèle. La precision évalue la proportion de prédictions positives correctes, tandis que le recall mesure la capacité du modèle à détecter correctement les différentes émotions. Enfin, le F1-score représente une moyenne harmonique entre la précision et le rappel, permettant une évaluation plus équilibrée des performances. Les résultats obtenus par le modèle sont présentés dans le tableau suivant :

Métrique	**Valeur**
Accuracy	57.63 %
Precision	57.99 %
Recall	57.63 %
F1-score	55.75 %

Table 7:Performances globales du modèle

Ces résultats montrent que le modèle est capable de reconnaître les émotions faciales avec des performances globalement satisfaisantes, malgré certaines difficultés liées aux similarités entre certaines expressions émotionnelles.

5.2 Résultats expérimentaux

L'entraînement du modèle MobileNetV2 a été réalisé en deux phases : une phase d'extraction de caractéristiques suivie d'une phase de fine-tuning. Les courbes d'apprentissage obtenues montrent une amélioration progressive des performances du modèle au fil des époques.

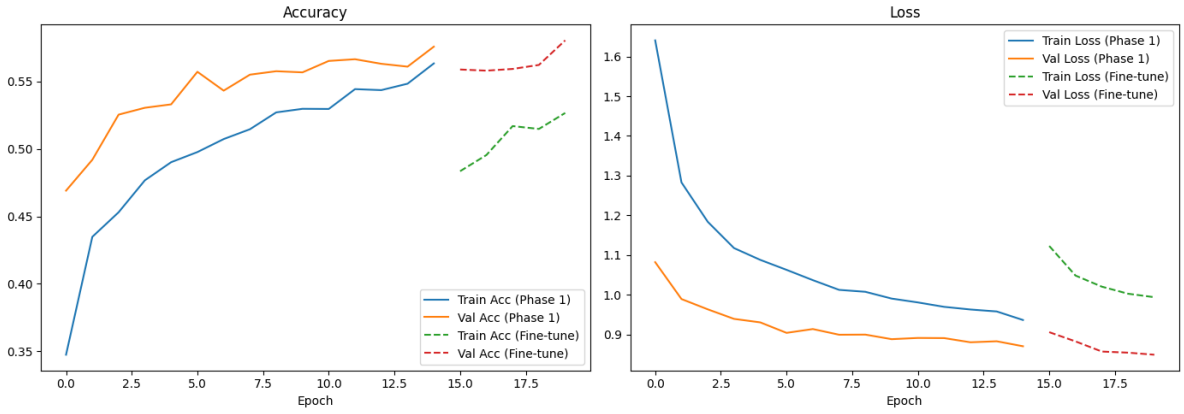


Figure 28:Évolution de l'accuracy et de la fonction de perte pendant l'entraînement

Les résultats montrent une augmentation progressive de l'accuracy d'entraînement et de validation, accompagnée d'une diminution de la fonction de perte (*loss*). Cela indique une bonne convergence du modèle au cours de l'apprentissage. On observe également que la phase de fine-tuning permet d'améliorer légèrement les performances globales du système. En effet, après le dégel des dernières couches de MobileNetV2, le modèle devient plus adapté aux caractéristiques spécifiques des expressions faciales présentes dans le dataset AffectNet.

5.3 Matrice de confusion

La matrice de confusion permet d'analyser en détail les performances du modèle pour chaque classe d'émotion.

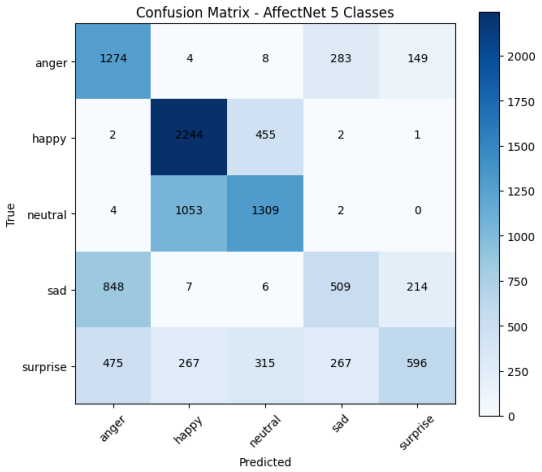


Figure 29:Matrice de confusion du modèle MobileNetV2 sur AffectNet

Les résultats montrent que certaines émotions sont mieux reconnues que d'autres. L'émotion happy présente le meilleur taux de classification, avec un grand nombre de prédictions correctes. En revanche, des confusions apparaissent entre certaines émotions visuellement proches, notamment neutral, sad et anger. On observe également que l'émotion surprise est parfois confondue avec d'autres classes, ce qui peut s'expliquer par les variations d'expression et les différences de pose présentes dans le dataset AffectNet.

5.4 Analyse des performances

L'analyse des résultats montre que le modèle obtient des performances globalement satisfaisantes pour la reconnaissance des émotions faciales. Les courbes d'apprentissage indiquent une convergence stable du modèle, tandis que la matrice de confusion met en évidence une bonne capacité de classification pour certaines émotions. Les meilleures performances sont observées pour les émotions fortement marquées comme happy, qui présente le plus grand nombre de prédictions correctes. En revanche, certaines difficultés apparaissent pour des émotions plus subtiles ou visuellement proches, notamment neutral, sad et anger. Ces confusions s'expliquent par la similarité des expressions faciales associées à ces émotions. Les performances du modèle sont également influencées par plusieurs facteurs, tels que le déséquilibre du dataset AffectNet, les variations d'éclairage, les angles de prise de vue ou encore la qualité des images. Malgré ces limitations, le modèle reste suffisamment rapide et précis pour une utilisation en temps réel dans l'application développée.

5.5 Comparaison des méthodes de détection (Haar Cascade vs YOLO)

Une comparaison entre les méthodes de détection Haar Cascade et YOLO a été réalisée afin d'évaluer leur impact sur les performances globales du système.

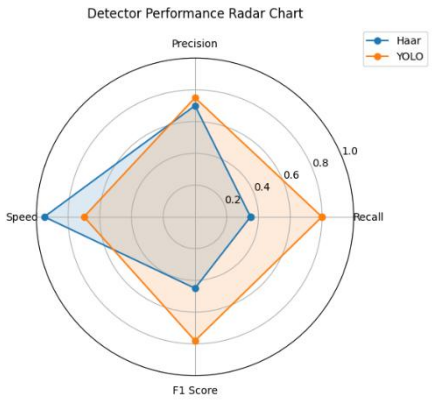


Figure 30:Comparaison des performances entre Haar Cascade et YOLO

Les résultats montrent que YOLO offre une meilleure robustesse et précision, notamment dans les images de groupe et les conditions complexes. En revanche, Haar Cascade est plus rapide, mais moins fiable dans les situations difficiles. Ainsi, YOLO est privilégié dans l'application finale pour améliorer la détection des visages avant la classification des émotions.

Chapitre 6 : Discussion et Limites

6.1 Analyse des erreurs

L'analyse des erreurs permet d'identifier les émotions les plus difficiles à classifier par le modèle

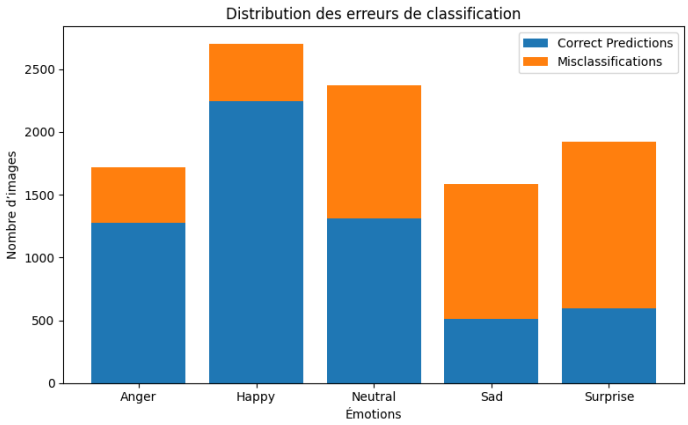


Figure 31:Distribution des erreurs de classification par émotion

Les résultats montrent que l'émotion happy présente le plus grand nombre de prédictions correctes, ce qui indique qu'elle est plus facilement reconnaissable par le modèle. En revanche, les émotions sad, neutral et surprise présentent davantage d'erreurs de classification. Ces confusions peuvent être expliquées par :

- La similarité des expressions faciales ;
- Le déséquilibre du dataset AffectNet ;
- Les variations d'éclairage et d'angle de prise de vue.

Globalement, cette analyse met en évidence les limites du modèle face aux émotions les plus subtiles ou ambiguës.

6.2 Cas problématiques

Le système rencontre davantage de difficultés dans certaines situations complexes, telles que les visages partiellement visibles, les visages de profil, les images de groupe, les faibles conditions de luminosité ou encore les occlusions (lunettes, cheveux, masques). Ces conditions peuvent réduire la qualité de détection des visages et entraîner des erreurs de classification des émotions, même avec l'utilisation de YOLO.

6.3 Impact de la qualité des données

Les performances du modèle dépendent fortement de la qualité et de la diversité des données d'entraînement. Bien que le dataset AffectNet soit riche et varié, certaines classes restent déséquilibrées, ce qui peut introduire des biais dans les prédictions. De plus, les variations d'expression, les différences culturelles ainsi que la qualité des images peuvent limiter la capacité du modèle à bien généraliser dans toutes les situations.

6.4 Limites du modèle

Malgré des performances satisfaisantes, le système présente plusieurs limites. Le modèle peut encore produire des erreurs dans des conditions réelles complexes ou face à des expressions ambiguës. Par ailleurs, bien que MobileNetV2 soit léger et adapté au temps réel, les performances restent inférieures à celles de modèles plus complexes et plus coûteux en ressources. Enfin, les métriques obtenues montrent que certaines émotions restent difficiles à distinguer avec précision.

6.5 Améliorations possibles

Plusieurs améliorations peuvent être envisagées afin d'augmenter les performances du système, notamment l'utilisation d'un dataset plus équilibré, l'intégration d'un plus grand nombre d'émotions, le test d'architectures plus récentes ainsi que l'amélioration des performances en temps réel. Des techniques avancées d'augmentation des données pourraient également renforcer la capacité de généralisation du modèle. Enfin, l'intégration d'approches multimodales combinant les expressions faciales avec la voix ou les gestes permettrait d'obtenir une reconnaissance émotionnelle plus précise et plus robuste.

Chapitre 7 : Aspects éthiques

7.1 Analyse éthique du système

La reconnaissance des émotions faciales soulève plusieurs enjeux éthiques liés à l'utilisation des données faciales et à l'interprétation des émotions humaines. Bien que cette technologie offre des applications intéressantes, son utilisation doit rester encadrée et responsable. Les images utilisées dans ce projet sont exploitées uniquement dans un cadre académique et expérimental. De plus, les prédictions générées par le modèle ne doivent pas être considérées comme totalement fiables, notamment dans des situations ambiguës ou complexes.

7.2 Fiche éthique

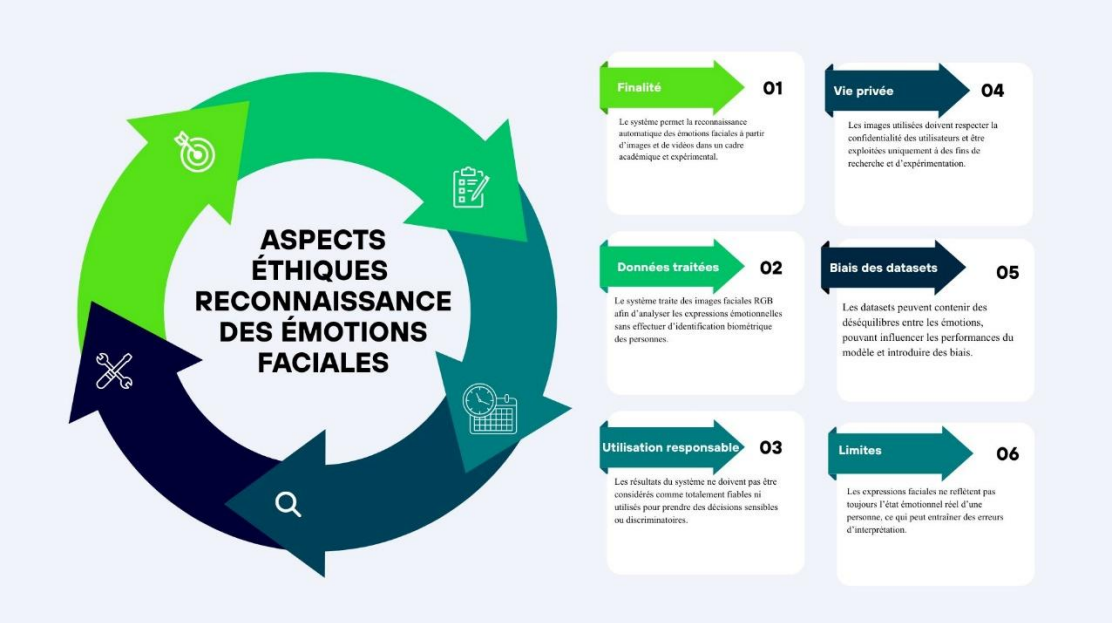


Figure 32:Aspects éthiques de la reconnaissance des émotions faciale

Cette fiche résume les principaux enjeux éthiques liés au système développé. Elle met en avant la protection de la vie privée, les biais potentiels des datasets, l'utilisation responsable de l'intelligence artificielle ainsi que les limites de l'interprétation automatique des émotions humaines.

7.3 Recommandations d’usage

Pour une utilisation responsable du système, plusieurs recommandations doivent être respectées :

- Utiliser le système uniquement à des fins académiques ou expérimentales ;
- Éviter toute prise de décision sensible basée uniquement sur les prédictions ;
- Informer les utilisateurs lorsque leurs images sont analysées ;
- Vérifier régulièrement les performances du modèle ;
- Respecter la confidentialité des données utilisées.

CONCLUSION GENERALE

Dans le cadre de ce projet, un système de reconnaissance des émotions faciales basé sur le Deep Learning a été développé afin d'analyser automatiquement les expressions émotionnelles à partir d'images et de flux vidéo. Le modèle MobileNetV2 a été utilisé comme architecture principale en raison de son bon compromis entre performance, rapidité et légèreté, ce qui le rend adapté aux applications en temps réel. Le système intègre plusieurs fonctionnalités, notamment la détection des visages à l'aide de Haar Cascade et YOLO, la classification des émotions ainsi qu'une interface web interactive développée avec Streamlit. Différents modes de fonctionnement ont été proposés, incluant l'analyse d'images simples, d'images de groupe et l'utilisation de la webcam en temps réel. Les résultats expérimentaux obtenus montrent que le modèle est capable de reconnaître les émotions faciales avec des performances globalement satisfaisantes. Toutefois, certaines limites persistent, notamment dans les situations complexes ou pour les émotions visuellement proches. Ce projet a également permis de mettre en évidence l'importance des aspects éthiques liés à l'utilisation de la reconnaissance des émotions faciales, en particulier concernant la protection de la vie privée, les biais des datasets et l'utilisation responsable de l'intelligence artificielle. Enfin, plusieurs perspectives d'amélioration peuvent être envisagées, telles que l'utilisation de modèles plus récents, l'intégration de nouvelles émotions ou encore le développement d'approches multimodales combinant les expressions faciales avec d'autres sources d'information.

WEBOGRAPHIE

[1] A. Mollahosseini et al., “AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild,” *IEEE TAC*, 2017. [Online]. Available: https://arxiv.org/abs/1708.03985.

[2] Wikipedia, “Histogram of Oriented Gradients,” 2026. [Online]. Available: https://en.wikipedia.org/wiki/Histogram_of_oriented_gradients.

[3] F. Schroff et al., “FaceNet: A Unified Embedding for Face Recognition and Clustering,” 2015. [Online]. Available: https://arxiv.org/abs/1503.03832.

[4] Wikipedia, “Active Appearance Model,” 2026. [Online]. Available: https://en.wikipedia.org/wiki/Active_appearance_model.

[5] IBM, “Support Vector Machine (SVM),” 2026. [Online]. Available: https://www.ibm.com/fr-fr/think/topics/support-vector-machine.

[6] U.S. EPA, “Random Forest Modeling,” 2026. [Online]. Available: https://www.epa.gov/streamflow-duration-assessment/random-forest-modeling.

[7] D. Jurafsky and J. H. Martin, *Speech and Language Processing*, Stanford University, 2025. [Online]. Available: https://web.stanford.edu/~jurafsky/slp3/A.pdf.

[8] A. G. Howard et al., “MobileNets: Efficient CNNs for Mobile Vision Applications,” 2017. [Online]. Available: https://arxiv.org/abs/1704.04861.

[9] M. Sandler et al., “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” 2018. [Online]. Available: https://arxiv.org/abs/1801.04381.

[10] A. Howard et al., “Searching for MobileNetV3,” 2019. [Online]. Available: https://arxiv.org/abs/1905.02244.

[11] Hugging Face, “Vision Transformer (ViT),” 2026. [Online]. Available: https://huggingface.co/docs/transformers/model_doc/vit.

[12] OpenCV Documentation, 2026. [Online]. Available: https://opencv.org/.

[13] Ultralytics, “YOLOv8 Documentation,” 2026. [Online]. Available: https://docs.ultralytics.com/.

[14] Streamlit Documentation, 2026. [Online]. Available: https://docs.streamlit.io/.

[15] TensorFlow Documentation, 2026. [Online]. Available: https://www.tensorflow.org/.

[16] Keras Documentation, 2026. [Online]. Available: https://keras.io/